

第一题

因为函数 f 与 g 定义在相同的区间，所以设定义域为 D ，则 fg 的定义域也为 D

$\because f$ 与 g 都是 D 上的凸函数

$\therefore \forall x_1, x_2 \in D, \forall \lambda \in [0, 1]$ ，有

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2) = A$$

$$g(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda g(x_1) + (1 - \lambda)g(x_2) = B$$

若 $h = fg$ 也为凸函数，则 $\forall x_1, x_2 \in D, \forall \lambda \in [0, 1]$ ，应有

$$h(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda h(x_1) + (1 - \lambda)h(x_2)$$

$$\Rightarrow f(\lambda x_1 + (1 - \lambda)x_2)g(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1)g(x_1) + (1 - \lambda)f(x_2)g(x_2) = C$$

比较 C 与 AB 的大小，若有 $AB \leq C$ 则 h 为凸函数：

$$\begin{aligned} AB - C &= [\lambda f(x_1) + (1 - \lambda)f(x_2)][\lambda g(x_1) + (1 - \lambda)g(x_2)] - [\lambda f(x_1)g(x_1) + (1 - \lambda)f(x_2)g(x_2)] \\ &= \lambda(\lambda - 1)(f(x_1) - f(x_2))(g(x_1) - g(x_2)) \end{aligned}$$

$\because f$ 与 g 都非减或非增

$$\therefore (f(x_1) - f(x_2))(g(x_1) - g(x_2)) \geq 0$$

$$\text{又 } \because \lambda(\lambda - 1) \leq 0$$

$$\therefore AB - C \leq 0 \Rightarrow AB \leq C$$

$\Rightarrow h = fg$ 为凸函数，证毕

第二题

将该优化问题写为标准形式：

$$\begin{aligned} &\text{Minimize} \quad \frac{1}{2}x^T Px + q^T x + r \\ &\text{Subject to} \quad -1 - x_i \leq 0, \quad i = 1, 2, 3 \\ &\quad \quad \quad x_i - 1 \leq 0, \quad i = 1, 2, 3 \end{aligned}$$

$$\text{其中，} P = \begin{pmatrix} 13 & 12 & -2 \\ 12 & 17 & 6 \\ -2 & 6 & 12 \end{pmatrix}, \quad q = \begin{pmatrix} -22.0 \\ -14.5 \\ 13.0 \end{pmatrix}, \quad r = 1$$

首先验证该优化问题为凸问题：

(1) 对于 $f_0(x)$ ，可以把它看作 $\frac{1}{2}x^T Px$ 和 $q^T x + r$ 的加权和 (权重均为 1)，分别验证两部分的凸性：

a. 易得仿射函数 $q^T x + r$ 为凸函数

b. $\frac{1}{2}x^T Px$ 二阶可微，因此检验其 Hessian 矩阵是否半正定：

$$\nabla^2(\frac{1}{2}x^T Px) = P \rightarrow \text{计算 } P \text{ 顺序主子式}$$

$$|P_1| = 13 > 0$$

$$|P_2| = \begin{vmatrix} 13 & 12 \\ 12 & 17 \end{vmatrix} = 85 > 0$$

$$|P_3| = |P| = 13(17 \cdot 12 - 6 \cdot 6) - 12(12 \cdot 12 - (-2) \cdot 6) + (-2)(12 \cdot 6 - 17 \cdot (-2)) = 324 > 0$$

$\Rightarrow P$ 为正定矩阵

$\therefore \frac{1}{2}x^T Px$ 为凸函数

\therefore 结合 a 与 b 可得 $f_0(x)$ 为凸函数

(2) 对于约束条件, $f_i(x) = \pm x_i - 1$ 均为仿射函数, 因此均为凸函数

\therefore 综合 (1) 和 (2), 该优化问题为凸问题

\therefore 原问题是凸问题时, 满足 KKT 条件的点即为该问题的最优解

首先, 满足 $-1 - x_i^* \leq 0, x_i^* - 1 \leq 0$

其次, 构造 Lagrange 函数:

$$L(x, \lambda) = \frac{1}{2}x^T Px + q^T x + r + \sum_{i=1}^3 \lambda_{1i}(-1 - x_i) + \sum_{i=1}^3 \lambda_{2i}(x_i - 1)$$

$$\therefore \nabla_x L = x^T P + q^T + (\lambda_1 - \lambda_2)^T$$

令 $\lambda_{1i}^*(-1 - x_i^*) = 0, \lambda_{2i}^*(x_i^* - 1) = 0, \nabla_x L = 0$, 代入 x^* 求解:

$$\text{解得 } \lambda_1^* = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad \lambda_2^* = \begin{pmatrix} 0 \\ 0 \\ 2 \end{pmatrix}$$

有解, 且解满足 $\lambda_i^* \geq 0, i = 1, 2$

$$\therefore \text{该问题的最优解为 } x^* = \begin{pmatrix} 1 \\ \frac{1}{2} \\ -1 \end{pmatrix}, \text{ 证毕}$$

第三题

(a) $\therefore (x-2)(x-4) \leq 0$

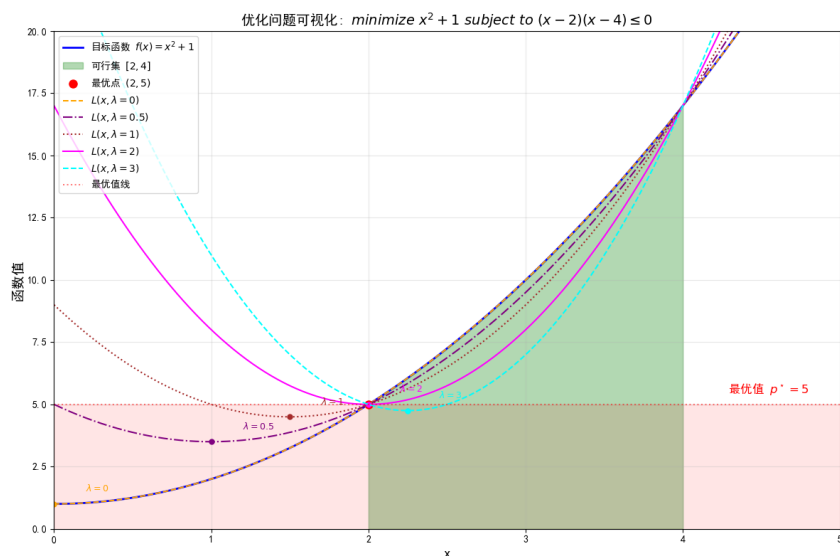
\therefore 可行集为 $[2, 4]$

$\therefore x \in [2, 4]$ 时, $f_0(x)_{\min} = 2^2 + 1 = 5$

\therefore 最优值为 $p^* = 5$, 最优解为 $x^* = 2$

(b) 构造 Lagrange 函数: $L(x, \lambda) = x^2 + 1 + \lambda(x-2)(x-4) = (1+\lambda)x^2 - 6\lambda x + (1+8\lambda)$

绘制目标函数图像并加入 λ 取正值的 Lagrange 函数曲线:



由图像中取的正 $\lambda = 0, 0.5, 1, 2, 3$, 可判断对于任意 $\lambda \geq 0$, 都有 $p^* \geq \inf_x L(x, \lambda)$, 下界性质得证

(c) 对偶函数 $g(\lambda) = \inf_x L(x, \lambda) = L(\frac{3\lambda}{1+\lambda}, \lambda) = \frac{1+9\lambda-\lambda^2}{1+\lambda} (\lambda \geq 0)$


寻找对偶问题的最优值： $g'(\lambda) = \frac{-\lambda^2-2\lambda+8}{(1+\lambda)^2} = \frac{9}{(1+\lambda)^2} - 1$ ，图像为开口向下的抛物线

$\therefore g'(\lambda) = 0 \Rightarrow$ 对偶最优解 $\lambda^* = 2$

\therefore 对偶最优值 $d^* = g(2) = 5$

$\therefore d^* = p^*$

\therefore 强对偶性成立



第四题

$$L(x, \lambda, \mu) = f_0(x) + \lambda f_1(x) + \mu h_1(x) = c^T x + \lambda^T (Gx - h) + \mu^T (Ax - b)$$

$$\rightarrow g(\lambda, \mu) = \inf_x L(x, \lambda, \mu) = -\lambda^T h - \mu^T b + \inf_x (c^T + \lambda^T G + \mu^T A)x$$

\therefore 若线性函数不是恒值，则其下确界是 $-\infty$

\therefore 该线性规划问题的对偶函数为：

$$g(\lambda, \mu) = \begin{cases} -\lambda^T h - \mu^T b, & c^T + \lambda^T G + \mu^T A = 0 \\ -\infty, & \text{其他情况} \end{cases}$$

\therefore 该线性规划的对偶问题为：

$$\begin{aligned} & \text{Maximize} && -\lambda^T h - \mu^T b \\ & \text{Subject to} && c^T + \lambda^T G + \mu^T A = 0 \\ & && \lambda \succeq 0 \end{aligned}$$

第五题

该问题的 KKT 条件如下：

$$\begin{aligned} \nabla f_0(x^*) + \nu^* \nabla h(x^*) &= 0 \\ h(x^*) &= 0 \end{aligned}$$

计算梯度：

$$\nabla f_0(x) = \begin{pmatrix} -6x_1 + 2 & 2x_2 + 2 & 4x_3 + 2 \end{pmatrix}, \quad \nabla h(x) = \begin{pmatrix} 2x_1 & 2x_2 & 2x_3 \end{pmatrix}$$

代入 KKT 条件，得方程组：

$$\begin{cases} -6x_1^* + 2 + 2\nu^* x_1^* &= 0 \\ 2x_2^* + 2 + 2\nu^* x_2^* &= 0 \\ 4x_3^* + 2 + 2\nu^* x_3^* &= 0 \\ x_1^{*2} + x_2^{*2} + x_3^{*2} - 1 &= 0 \end{cases}$$

借助计算器得到三个解，满足 KKT 条件的所有点为：

$$\begin{aligned} \text{点 1: } x &\approx \begin{pmatrix} 0.1626 \\ 0.4651 \\ 0.8696 \end{pmatrix}, \quad \nu \approx -3.1500, \\ \text{点 2: } x &\approx \begin{pmatrix} 0.3604 \\ -0.8163 \\ -0.4494 \end{pmatrix}, \quad \nu \approx 0.2250, \\ \text{点 3: } x &\approx \begin{pmatrix} -0.9662 \\ -0.1986 \\ -0.1657 \end{pmatrix}, \quad \nu \approx 4.0350. \end{aligned}$$

求最优解，计算每一个点对应的 $f_0(x)$ 值：

$$\begin{aligned} \text{点 1: } f_0(x) &\approx -3(0.1626)^2 + (0.4651)^2 + 2(0.8696)^2 + 2(0.1626 + 0.4651 + 0.8696) \\ &\approx 4.6441, \end{aligned}$$

$$\begin{aligned} \text{点 2: } f_0(x) &\approx -3(0.3604)^2 + (-0.8163)^2 + 2(-0.4494)^2 + 2(0.3604 - 0.8163 - 0.4494) \\ &\approx -1.1299, \end{aligned}$$

$$\begin{aligned} \text{点 3: } f_0(x) &\approx -3(-0.9662)^2 + (-0.1986)^2 + 2(-0.1657)^2 + 2(-0.9662 - 0.1986 - 0.1657) \\ &\approx -5.3672. \end{aligned}$$

因此点 3 的 f_0 最小，故点 3 为最优解，最优值为-5.3672，

$$\text{即 } x^* \approx \begin{pmatrix} -0.9662 \\ -0.1986 \\ -0.1657 \end{pmatrix}, \quad f_0(x^*) \approx -5.3672.$$

第六题

(1) 充分性：若 $\nabla^2 f(x) \succeq 0$ ($\forall x \in D$)，则对任意 $x, y \in D$ 与 $t \in [0, 1]$ ，考虑一维函数

$$g(t) = f(x + t(y - x)), \quad t \in [0, 1].$$

由链式法则，

$$g'(t) = \nabla f(x + t(y - x))^T (y - x), \quad g''(t) = (y - x)^T \nabla^2 f(x + t(y - x)) (y - x) \geq 0.$$

故 g 在区间 $[0, 1]$ 上为一维凸函数，于是

$$g(t) \leq (1 - t)g(0) + tg(1) = (1 - t)f(x) + tf(y).$$

令 $t = \lambda$ 即得

$$f((1-\lambda)x + \lambda y) \leq (1-\lambda)f(x) + \lambda f(y), \quad \forall \lambda \in [0, 1].$$

因此 f 是凸函数，故充分性成立。

(2) 必要性：若 f 凸且 $f \in C^2(D)$ ，取任意点 $x \in D$ 与任意方向 $d \in \mathbb{R}^n$ ，考虑一维函数

$$\phi(t) = f(x + td), \quad t \text{ 在使 } x + td \in D \text{ 的某开区间内.}$$

由于 f 凸， ϕ 亦凸（一维线性组合保持凸性）。

因此对一维二阶可微凸函数必有 $\phi''(0) \geq 0$ 。计算二阶导：

$$\phi''(0) = d^T \nabla^2 f(x) d \geq 0, \quad \forall d \in \mathbb{R}^n.$$

于是 $\nabla^2 f(x)$ 的二次型非负，说明 Hessian 半正定。

由于 x 与 d 任取，得 $\nabla^2 f(x) \succeq 0$ 对所有 $x \in D$ 成立，必要性证明完毕。

综上， f 是凸函数 $\iff \nabla^2 f(x) \succeq 0$ （对所有 $x \in D$ ），命题得证。

第七题

叶荫宇, 斯坦福大学李国鼎讲席教授, 2009 年荣获 INFORMS 冯·诺依曼理论奖, 是首位获此殊荣的华人科学家。其主要学术贡献包括:

- 优化算法与复杂性理论

- 内点法奠基: 在线性规划内点法理论研究中做出开创性工作
- 原始-对偶预测-校正框架: 显著提升大规模线性规划问题求解效率
- 分布式鲁棒优化: 为不确定性决策提供理论工具

- 锥优化与半定规划

- 系统发展锥规划模型, 统一并推广线性与凸优化理论
- 应用于传感器网络定位, 提出基于半定规划的节点定位方法

- 算法求解器与工业应用

- 参与开发优化求解器 COPT, 将求解速度提升 3 倍以上
- 研究成果应用于电力系统调度、高速铁路规划等领域

- 在线优化与学习算法

- 推动在线线性规划发展, 提出自适应决策方法
- 在强化学习与马尔可夫决策过程复杂度分析中做出贡献

- 学术荣誉

- 2009 年冯·诺依曼理论奖 (INFORMS)
- 2012 年国际数学规划大会 Tseng Lectureship 奖
- 2014 年 SIAM 优化奖
- 谷歌学术引用超 65,000 次